

COE-835 Controle adaptativo

Simulações do Trabalho 2

Grupo: Guilherme Pires Sales de Carvalho
Matheus Ferreira dos Reis
Renan Salles de Freitas

Algoritmo: Identificação de parâmetros

Caso: $n = 1, 2, 3$ (ordem da planta)
 $n^* = 1$ (grau relativo)
 $n_p = 2, 4, 6$ (# de parâmetros)

Conteúdo

1	Resumo das equações do método	2
2	Identificação de parâmetros	3
3	Diagramas de blocos	4
4	Discussão	5

1 Resumo das equações do método

Abaixo, resumimos algumas das principais equações utilizadas no método.

2 Identificação de parâmetros

Identificação de parâmetros é usar a coleção de sinais disponíveis do sistema, baseado em algum critério de otimalidade e informação da estrutura, para produzir uma estimativa dos parâmetros desconhecidos da planta. Identificação adaptativa dos parâmetros é um procedimento de estimação dinâmica que faz uso da atualização dos sinais do sistema para estimar os parâmetros desconhecidos, atualizados on-line. A identificação adaptativa de parâmetros é crucial para o projeto de controladores adaptativos, onde os parâmetros de controle devem ser atualizados on-line ao mesmo tempo em que o sistema está em operação.

Considere um sistema linear invariante no tempo descrito pela equação diferencial (Eq. 1):

$$P(s)[y](t) = Z(s)[u](t), \quad (1)$$

onde $y(t) \in \mathbb{R}$ e $u(t) \in \mathbb{R}$ são os sinais medidos de saída e entrada do sistema e

$$P(s) = s^n + p_{n-1}s^{n-1} + \dots + p_1s + p_0, \quad (2)$$

$$Z(s) = z_ms^m + z_{m-1}s^{m-1} + \dots + z_1s + z_0 \quad (3)$$

são os polinômios em s , s sendo o operador de diferencial $s[x](t) = \dot{x}(t)$; e $p_i, i = 0, 1, \dots, n-1$, $z_i, i = 0, 1, \dots, m$ com $n > m$, são os parâmetros desconhecidos da planta.

Escolhe-se um polinômio estável $\Lambda(s) = s^n + \lambda_{n-1}s^{n-1} + \dots + \lambda_1s + \lambda_0$. Multiplicando ambos os lados da equação 1 pelo filtro $\frac{1}{\Lambda(s)}$, temos:

$$y(t) = \frac{Z(s)}{\Lambda(s)}[u](t) + \frac{\Lambda(s) - P(s)}{\Lambda(s)}[y](t). \quad (4)$$

Introduzindo o vetor de parâmetros e regressor:

$$\theta^* = [z_0, z_1, \dots, z_{m-1}, z_m, \lambda_0 - p_0, \lambda_1 - p_1, \dots, \lambda_{n-2} - p_{n-2}, \lambda_{n-1} - p_{n-1}]^T \in \mathbb{R}^{n+m+1}, \quad (5)$$

$$\begin{aligned} \phi(t) = & \left[\frac{1}{\Lambda(s)}[u](t), \frac{s}{\Lambda(s)}[u](t), \dots, \frac{s^{m+1}}{\Lambda(s)}[u](t), \frac{s^m}{\Lambda(s)}[u](t), \right. \\ & \left. \frac{1}{\Lambda(s)}[y](t), \frac{s}{\Lambda(s)}[y](t), \dots, \frac{s^{n-2}}{\Lambda(s)}[y](t), \frac{s^{n-1}}{\Lambda(s)}[y](t) \right]^T \in \mathbb{R}^{n+m+1}, \end{aligned} \quad (6)$$

podemos expressar 4 como:

$$y(t) = \theta^{*T} \phi(t). \quad (7)$$

A implementação do filtro é realizada pela construção de dois sistemas dinâmicos, na realização de estados:

$$\dot{\omega}_1(t) = A_\lambda \omega_1(t) + bu(t) \quad (8)$$

$$\dot{\omega}_2(t) = A_\lambda \omega_2(t) + by(t), \quad (9)$$

onde $\omega_1(t) \in \mathbb{R}^n$, $\omega_2(t) \in \mathbb{R}^n$ e

$$A_\lambda = \begin{bmatrix} 0 & 1 & 0 & \dots & 0 & 0 \\ 0 & 0 & 1 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \dots & \dots & 0 & 1 \\ -\lambda_0 & -\lambda_1 & \dots & \dots & -\lambda_{n-2} & -\lambda_{n-1} \end{bmatrix}, b = \begin{bmatrix} 0 \\ \vdots \\ 0 \\ 1 \end{bmatrix} \in \mathbb{R}^n \quad (10)$$

E o vetor regressor $\phi(t)$ pode ser escrito como:

$$\phi(t) = [(C_m \omega_1(t))^\top, \omega_2^\top(t)]^\top, \quad (11)$$

$$C_m = [I_{m+1}, 0_{(m+1) \times (n-m-1)}] \in \mathbb{R}^{(m+1) \times n}. \quad (12)$$

Onde, I_{m+1} é a matriz identidade de dimensão $(m+1) \times (m+1)$.

Considere $\theta(t)$ a estimativa dos parâmetros θ^* . O erro de estimação pode ser definido como:

$$\epsilon(t) = \theta^\top(t) \phi(t) - y(t) = \tilde{\theta}^\top(t) \phi(t), t \geq t_0. \quad (13)$$

Neste trabalho, serão considerados dois algoritmos para a atualização da estimação dos parâmetros (θ): método do gradiente normalizado e método *least-square*.

O algoritmo do gradiente normalizado para atualização da estimação dos parâmetros corresponde escolher a derivada de $\theta(t)$ na direção do gradiente descendente, minimizando a função custo normalizada:

$$J(\theta) = \frac{\epsilon^2}{2m^2} = \frac{\tilde{\theta}^\top \phi \phi^\top \tilde{\theta}}{2m^2}, \quad (14)$$

$$m^2 = 1 + \kappa \phi^\top(t) \phi \quad (15)$$

Derivando-se a função custo, obtém-se a lei de adaptação paramétrica:

$$\dot{\theta}(t) = -\frac{\Gamma \phi(t) \epsilon(t)}{m^2(t)}, \theta(t_0) = \theta_0, t \geq t_0, \quad (16)$$

onde $\Gamma = \Gamma^\top > 0$ é uma matrix de ganhos. Vale observar que é possível provar por Lyapunov a estabilidade e convergência de $\epsilon = \theta^\top(t) \phi(t) - y(t)$ para zero. Porém, esta condição não garante $\tilde{\theta} = 0$, apenas garante a ortogonalidade entre os vetores dos parâmetros e regressor. A convergência é garantida quando há excitação persistente no sistema.

No caso do algoritmo *least-square* normalizado, a atualização paramétrica é dada pela equação:

$$\dot{\theta}(t) = -\frac{P(t) \phi(t) \epsilon(t)}{m^2(t)}, \theta(t_0) = \theta_0, t \geq t_0, \quad (17)$$

$$\dot{P}(t) = -\frac{P(t) \phi(t) \phi^\top(t) P(t)}{m^2(t)}, P(t_0) = P_0 = P_0^\top > 0, t \geq t_0, \quad (18)$$

$$m^2(t) = 1 + \kappa \phi^\top(t) P(t) \phi(t), \kappa > 0. \quad (19)$$

3 Diagramas de blocos

4 Discussão